



UNIVERSITÀ DEGLI STUDI GUGLIELMO MARCONI

DIPARTIMENTO DI INGEGNERIA

CORSO DI LAUREA IN INTELLIGENZA ARTIFICIALE (L-8)

*“Curriculum e mixed-batch learning a confronto nel
Reinforcement Learning multi-agente per la guida autonoma in
ambiente simulato urbano”*

Relatore:

Prof. Stefano Aldegheri

Candidato:

Fabio Carapelle

Sommario

L'ordine in cui i task di addestramento vengono presentati è una decisione di progetto nel Reinforcement Learning i cui effetti sono raramente isolati nei contesti multi-agente. Questa tesi confronta il *curriculum learning* — progressione dei task da facile, medio a difficile, condizionata dalla competenza misurata — con l'addestramento *mixed-batch*, che alterna uniformemente tutte le difficoltà fin dall'inizio, per la guida autonoma in un contesto urbano simulato (CARLA), con sei agenti (tre veicoli e tre pedoni) che apprendono simultaneamente come muoversi in un unico mondo condiviso sfruttando l'algoritmo MAPPO ed un critic centralizzato. Una campagna 2×2 appaiata per seed incrocia i due regimi con due encoder del critic (MLP e GNN) a tre milioni di passi per run, su una piattaforma irrobustita da un protocollo di sviluppo guidato da gate e misurata con un criterio di successo rigoroso, con repliche a seed identico a fornire una banda di rumore esplicita. L'ordinamento dei task non ha accelerato l'apprendimento iniziale: tutte le celle hanno superato le stesse soglie di competenza agli stessi conteggi di passi. Ha invece selezionato *che cosa* la policy è diventata. Con il critic MLP/GNN il curriculum ha prodotto un guidatore cauto e con più successi, il batch invece uno veloce e incline alle collisioni; Sul criterio di successo, il curriculum ha prevalso di +18.5 punti percentuali ponderati in valutazione dei veicoli. In entrambe le architetture del critic il curriculum ha prevalso su una città mai vista in addestramento (+19.0 e +10.0 pp). I pedoni sono risultati vincolati dalla fattibilità dei percorsi più che dal regime e per questo non sono stati tenuti prettamente "rilevanti" al fine della valutazione, ma sono stati considerati per evidenziare come diversi attori influenzino gli altri all'interno del mondo usando un criterio di CTDE. L'ordinamento dei task, in questo contesto, è un selettore di equilibri il cui beneficio in-domain dipende dalla stima del valore — e il cui output più evidente è la generalizzazione ed un tempo di esecuzione della run minore a parità di budget a favore del training curriculum.

Indice

Acronimi	v
1 Introduzione	1
1.1 Motivazione e domanda di ricerca	1
1.2 Fondamenti essenziali	2
1.3 Approccio, contributi e struttura	4
2 Il progetto — la piattaforma sperimentale	6
2.1 Panoramica dell’architettura	6
2.2 Un mondo condiviso: la copertura parallela dei task	7
2.3 Spazi di osservazione e azione	8
2.4 Design della reward	9
2.5 Generazione dei percorsi e livelli di difficoltà	10
2.6 I due regimi di addestramento	10
2.7 Encoder del critic, ottimizzazione e valutazione	11
3 Il progetto — metodo e campagna	13
3.1 Metriche e regole di misura	13
3.2 Protocollo di sviluppo guidato da gate	14
3.3 Validità dell’ambiente: bug trovati e corretti	15
3.4 Design della campagna finale	16
4 Il progetto — risultati e discussione	17
4.1 Integrità della campagna	17
4.2 Efficienza campionaria	17
4.3 Prestazione finale	18
4.4 Dinamica entro la run	20
4.5 Generalizzazione: da Town03 a Town05	21
4.6 Asse architetturale: critic MLP contro GNN	22
4.7 Limiti strutturali dei pedoni	23
4.8 Verdetti sulle ipotesi	24
4.9 Discussione	25

4.10	Minacce alla validità e limiti di scope	26
5	Possibili evoluzioni	27
5.1	Consolidare l'evidenza	27
5.2	Rimuovere i limiti della piattaforma	28
5.3	Estendere la domanda	28
6	Conclusioni	29
A	Osservazioni e reward per componente	31
B	Registro condensato degli esperimenti	33
C	Configurazione e iperparametri	35
D	Riproducibilità	37
	Bibliografia	39

Acronimi

CTDE	Centralized Training with Decentralized Execution
GAE	Generalized Advantage Estimation
GNN	Graph Neural Network
MAPPO	Multi-Agent Proximal Policy Optimization
MARL	Multi-Agent Reinforcement Learning
MLP	Multi-Layer Perceptron
NPC	Non-Player Character (partecipante al traffico con comportamento scriptato)
PPO	Proximal Policy Optimization
RL	Reinforcement Learning
SR	Success Rate (tasso di successo)
TM	(CARLA) Traffic Manager

Capitolo 1

Introduzione

1.1 Motivazione e domanda di ricerca

L'apprendimento per rinforzo (*reinforcement learning*, RL) addestra politiche di controllo per tentativi ed errori, e in qualunque dominio non banale il progettista incontra una decisione di scheduling prima ancora del primo passo di gradiente: quando i task da padroneggiare coprono un intervallo di difficoltà, *in quale ordine vanno presentati?* Due risposte sono naturali e opposte. Il *curriculum learning* li presenta dal facile al difficile, sulla falsariga della pedagogia umana: si costruisce competenza dove il successo è raggiungibile, poi la si estende. L'*addestramento misto* (mixed-batch) li presenta tutti fin dall'inizio, ed è l'analogo diretto dell'addestramento su un dataset mescolato, default indiscusso dell'apprendimento supervisionato.

Le due strategie consumano lo stesso budget di calcolo: scegliere tra loro è, in linea di principio, gratuito. Se la scelta cambia ciò che la policy appresa fa, allora è tra le leve più economiche a disposizione di chi progetta un sistema di RL — ed è anche tra le meno caratterizzate nei contesti *multi-agente*, dove quasi nessuna delle assunzioni della letteratura sui curricula (apprendista singolo, reward sparse, ambiente stazionario) continua a valere.

La guida autonoma urbana è un banco di prova esigente per porre la domanda: offre un asse di difficoltà naturale e continuo (la lunghezza del percorso), agenti eterogenei con vincoli fisici diversi, una tensione strutturale tra prestazione e sicurezza — le policy più veloci completano più percorsi e urtano più cose — e un test out-of-distribution canonico, guidare su una città mai vista in addestramento. È inoltre intrinsecamente multi-agente: le policy non si limitano a condividere un mondo, ma plasmano l'ambiente l'una dell'altra mentre apprendono.

Il curriculum learning da easy a medium a hard produce un comportamento di guida multi-agente misurabilmente diverso rispetto all'addestramento mixed-batch, a parità di budget di addestramento?

La domanda riguarda deliberatamente il *comportamento* e non una singola classifica di tassi di successo: il confronto è valutato lungo quattro assi — efficienza campionaria iniziale, prestazione finale con la sua composizione dei fallimenti, dinamica entro la run e generalizzazione a una mappa nuova — sempre separando veicoli e pedoni. Tre ipotesi falsificabili strutturano l’analisi:

- **H1 (curriculum).** L’esposizione graduale produce una migliore efficienza campionaria iniziale, perché i task facili offrono successi raggiungibili da cui partire; con il rischio noto di plateau od oblio sui task difficili introdotti tardi.
- **H2 (misto).** L’esposizione uniforme copre l’intera distribuzione dei task dal passo zero, al costo di un segnale iniziale più rumoroso; il suo payoff atteso è la robustezza.
- **H3 (interazione, secondaria).** L’entità — forse la direzione — dell’effetto di regime può dipendere da come viene stimato il valore: nelle architetture ad addestramento centralizzato è il *critic* a digerire la struttura multi-agente, e sostituirne l’encoder può cambiare ciò che l’ordinamento produce.

1.2 Fondamenti essenziali

Questa sezione introduce solo i concetti effettivamente usati nel seguito, ciascuno alla profondità alla quale serve.

RL, valore e vantaggio. Il RL formalizza la decisione sequenziale come processo decisionale di Markov $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$ [1]: un agente agisce tramite una policy $\pi(a \mid s)$ e massimizza il ritorno atteso scontato $J(\pi) = \mathbb{E}_{\pi}[\sum_{t \geq 0} \gamma^t r(s_t, a_t)]$. Lo sconto fissa un orizzonte decisionale effettivo di $\approx 1/(1 - \gamma)$ passi: non è una costante cosmetica, perché la piattaforma del Capitolo 2 usa $\gamma = 0.997$, cioè ≈ 333 passi, su episodi lunghi fino a mille passi. Il *vantaggio* $A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s)$ misura quanto un’azione sia migliore della media della policy in quello stato, e il teorema del gradiente di policy fornisce $\nabla_{\theta} J = \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) A^{\pi}(s_t, a_t)]$. Poiché stimare A con ritorni Monte Carlo grezzi produce alta varianza, si sottrae una baseline appresa: i metodi *actor-critic* addestrano perciò l’actor π_{θ} e il critic V_{ϕ} — e questa divisione del lavoro è l’aggancio all’architettura multi-agente, perché il critic è un dispositivo del solo addestramento e può quindi ricevere informazione che l’actor non vede mai.

PPO, GAE ed entropia. Gli aggiornamenti di gradiente “vanilla” sono fragili, perché un singolo passo troppo grande può far collassare una policy funzionante. PPO [2] lo evita con un obiettivo surrogato clippato: detto $\rho_t(\theta) = \pi_{\theta}(a_t \mid s_t) / \pi_{\theta_{\text{old}}}(a_t \mid s_t)$ il rapporto di importanza,

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t A_t, \text{clip}(\rho_t, 1 - \varepsilon, 1 + \varepsilon) A_t \right) \right], \quad (1.1)$$

il che rimuove ogni incentivo a spostare il rapporto oltre $[1 - \varepsilon, 1 + \varepsilon]$ e permette più epoche di gradiente su ogni batch senza aggiornamenti distruttivi. I vantaggi A_t provengono da GAE [3], che con i residui temporali $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ pone $A_t = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}$, dove λ scambia bias e varianza tra il TD a un passo e i ritorni Monte Carlo, e la cui qualità dipende direttamente da quella del critic. Un bonus di entropia sostiene infine l'esplorazione penalizzando il collasso prematuro della policy.

MARL, CTDE e MAPPO. Con N agenti in un unico ambiente DP si generalizza a un *gioco di Markov*, e sorgono due difficoltà strutturali. La prima è la *non-stazionarietà*: dal punto di vista di ciascun agente gli altri sono parte dell'ambiente e stanno apprendendo, quindi la dinamica effettiva cambia nel tempo e l'esperienza raccolta sotto vecchie policy dei co-giocatori diventa fuorviante [4]. La seconda è l'*attribuzione del merito*: il ritorno di ogni agente dipende dalle azioni di tutti. La risoluzione ormai standard sfrutta la divisione actor-critic: si addestrano i critic con accesso a informazione globale, mantenendo gli actor condizionati sulle sole osservazioni locali [4]. Il critic assorbe la non-stazionarietà, mentre l'esecuzione resta pienamente decentralizzata perché i critic vengono scartati dopo l'addestramento: è il paradigma *centralized training, decentralized execution* (CTDE), usato in tutta questa tesi. MAPPO [5] lo istanzia con actor PPO e funzione di valore centralizzata, e Yu et al. mostrano che questa combinazione minimale eguaglia o supera i metodi off-policy sui benchmark cooperativi standard purché i dettagli implementativi siano corretti — fra i quali proprio il design dell'input del critic. Nel critic più semplice quell'input è la concatenazione piatta delle osservazioni di tutti gli agenti; le alternative strutturate le trattano come nodi di un grafo, ed è il confronto tra queste due famiglie a costituire l'asse secondario di questa tesi (Sezione 2.7).

Curriculum learning e la sua condizione di controllo. L'idea che l'apprendimento migliori quando gli esempi sono presentati in un ordine sensato precede il deep learning: gli esperimenti *starting small* di Elman mostrarono reti ricorrenti capaci di apprendere una grammatica complessa solo quando la complessità dell'input cresceva incrementalmente [6], e Bengio et al. [7] diedero poi alla strategia il nome di curriculum learning, inquadrandola come metodo di continuazione in cui gli esempi facili definiscono una versione più liscia dell'obiettivo. Nel RL il progettista controlla non solo l'ordine dei dati ma la distribuzione dei *task*, il che rende i curricula al tempo stesso più potenti e più difficili da progettare; nella tassonomia della survey di Narvekar et al. [8] il meccanismo della Sezione 2.6 è uno schema di *sequenziamento* basato sulla prestazione su un insieme fisso di task. La motivazione riguarda in larga parte l'esplorazione: sui task difficili una policy debole può non sperimentare praticamente mai il successo, e quindi non ricevere segnale di apprendimento. Tre modi di fallimento noti hanno plasmato il design del Capitolo 2 — l'*oblio* della competenza precedente sotto distribuzione spostata [9], lo *stallo* su un gate

mai soddisfatto e la *mis-calibrazione* del gate stesso — e sono esattamente i rischi che H1 mette alla prova. Ogni affermazione sull’ordinamento richiede però una baseline in cui esso è *assente*, ed è la condizione che **il braccio** batch implementa.

Il simulatore CARLA. CARLA [10] è un simulatore open-source di guida urbana su Unreal Engine 4, distribuito come server che ospita mondo e fisica e pilotato da client via API Python. Conta qui per tre ragioni (versione 0.9.16 ovunque): la *modalità sincrona a passo fisso* rende la raccolta di esperienza indipendente dal rendering; i pedoni sono attori *walker* ad azionamento diretto, il che rende possibile apprenderne le policy; e le città fornite differiscono *in natura* e non solo in dimensione — l’addestramento usa *Town03*, “a larger, urban map with a roundabout and large junctions”, il test di generalizzazione *Town05*, una “squared-grid town with cross junctions and a bridge” a più corsie per direzione [11]. Anche in modalità sincrona e con tutti i seed fissati, infine, CARLA sotto carico multi-agente non è deterministico da run a run: una variabilità irriducibile quantificata e usata come metro per ogni effetto riportato (Sezione 3.2).

1.3 Approccio, contributi e struttura

Tutti gli esperimenti girano su Town03, con Town05 riservata al solo test di generalizzazione. Sei agenti apprendono simultaneamente in un unico mondo condiviso — tre veicoli e tre pedoni, ciascuno con un percorso proprio a ogni episodio — un design che chiamiamo *copertura parallela dei task* e che è la cornice fissa di entrambi i bracci sperimentali, non una variabile. Le policy sono addestrate con MAPPO in regime CTDE, con una policy condivisa per classe e un critic centralizzato che vede le osservazioni di tutti gli agenti solo durante l’addestramento; la difficoltà è la lunghezza target del percorso (30/60/100 m) e il successo è il completamento rigoroso del percorso assegnato.

I due regimi condividono ogni componente tranne la regola di selezione del livello: il braccio *curriculum* parte dal solo easy e sblocca i livelli successivi attraverso un gate di competenza a finestra, il braccio *batch* alterna uniformemente tutti i livelli fin dal primo episodio. La campagna finale è un fattoriale 2×2 — {critic MLP, critic GNN} $\times$ {curriculum, batch} — di **quattro** run da tre milioni di passi a seed singolo appaiato, ciascuna seguita da una valutazione di 400 episodi che include Town05. **Con una run per cella ogni contrasto è un caso di studio appaiato, letto contro una banda di varianza misurata su repliche a seed identico; il contrasto primario è però osservato due volte, una per architettura del critic. Anticipando il Capitolo 4: la clausola di efficienza di H1 e quella di robustezza di H2 falliscono entrambe, mentre H3 regge in forma forte.**

I contributi sono quattro: **(i)** un framework di confronto controllato a parità di budget, con run appaiate per seed e regole di misura rigorose per agente; **(ii)** una metodologia di sviluppo guidata da gate con un registro onesto di modifiche promosse, rigettate e

consapevolmente mantenute, in cui i difetti di validità dell'ambiente — incluso uno che ha spostato la metrica principale di ≈ 50 punti percentuali senza alcun cambiamento di policy — sono documentati con le loro firme di rilevamento; **(iii)** una caratterizzazione empirica di che cosa fa l'ordinamento dei task, ossia nessun effetto di efficienza iniziale ma selezione tra equilibri di guida qualitativamente diversi; e **(iv)** l'evidenza che gli effetti di regime sono condizionati dalla stima del valore.

La tesi prosegue in quattro blocchi. I Capitoli 2 **to** 4 descrivono il progetto: rispettivamente la piattaforma sperimentale, il metodo di misura con il design della campagna, e i risultati con la loro interpretazione. Il Capitolo 5 raccoglie le possibili evoluzioni del lavoro e il Capitolo 6 **conclude**.

Capitolo 2

Il progetto — la piattaforma sperimentale

Questo capitolo descrive la piattaforma su cui poggia l'esperimento: un ambiente di apprendimento per rinforzo multi-agente costruito su CARLA, in cui tre veicoli e tre pedoni sono addestrati congiuntamente **con MAPPO** sotto due regimi alternativi — curriculum e mixed-batch — che condividono ogni altro componente dello stack. L'obiettivo di design è che il regime sia l'*unica* variabile indipendente dell'esperimento: tutto ciò che è documentato qui è comune a entrambi i bracci, e la Sezione 2.6 isola il punto esatto in cui divergono.

2.1 Panoramica dell'architettura

La piattaforma consiste di quattro strati (Figura 2.1). Il **simulatore** è CARLA 0.9.16, che gira come server autonomo pilotato in modalità sincrona con passo di fisica fisso di 0.05 s (20 Hz): avanza solo quando l'ambiente emette un tick, il che rende la raccolta di esperienza deterministica rispetto allo scheduling. Il traffico scriptato non apprendente — 15 veicoli e 30 pedoni NPC in ogni livello — è gestito dal Traffic Manager, anch'esso sincrono. L'**ambiente multi-agente** (`CarlaMultiAgentEnv`) espone la simulazione a RLlib come interfaccia multi-agente con sei agenti apprendenti: a ogni reset spawna gli agenti, assegna a ciascuno un percorso individuale (Sezione 2.5) e configura lo scenario secondo il livello selezionato dal manager curriculum/batch (Sezione 2.6); un episodio dura al più **mille** passi di controllo, cioè 50 s di tempo simulato.

Lo **stack di apprendimento** è MAPPO su Ray/RLlib 2.10.0 con PyTorch 2.7. Vengono apprese due policy, una condivisa dai tre veicoli e una dai tre pedoni — condivisione di parametri entro ciascuna classe, nessuna condivisione tra classi, poiché le due hanno spazi di osservazione e azione diversi. Ogni actor è un percettore multistrato con due strati nascosti da 256 unità; un critic centralizzato riceve un'osservazione globale a 225




Figura 2.1: Architettura a componenti. Il manager curriculum/batch è l’unico componente che differisce tra i due bracci sperimentali, e solo nella regola di selezione del livello (Sezione 2.6).

dimensioni che concatena informazione per agente (Sezione 2.3), con encoder MLP di default e una variante a grafo come asse sperimentale secondario (Sezione 2.7). Infine il **logging**: alla fine di ogni episodio il processo di addestramento accoda un record JSON *per agente* — sei per episodio — a un file `episodes.jsonl` contenente ragione di terminazione, completamento ed efficienza del percorso, velocità e diagnostica di generazione del percorso. Tutti i risultati del Capitolo 4 sono calcolati da questi record.

2.2 Un mondo condiviso: la copertura parallela dei task

I sei agenti apprendenti non cooperano verso un obiettivo congiunto: a ciascuno è assegnato il *proprio* percorso ed è valutato individualmente sul suo completamento. Poiché tutti e sei i percorsi sono collocati nello stesso mondo vivo, un singolo episodio esercita simultaneamente sei micro-task diversi — geometrie stradali diverse, interazioni diverse con il traffico scriptato e, soprattutto, interazioni reciproche tra agenti apprendenti, per esempio un veicolo che dà la precedenza a un pedone anch’esso in addestramento. Chiamiamo questo design *copertura parallela dei task*: per episodio di orologio il sistema raccoglie esperienza su sei istanze di task anziché una. Rispetto ai benchmark cooperativi che motivano MAPPO, il setting è meglio descritto come *coesistenza* di task indipendenti in un mondo condiviso — nessuna reward di squadra, nessuna competizione esplicita, ma un accoppiamento reale attraverso lo stato del mondo.

Ne seguono due avvertenze. Primo, i sei campioni per episodio sono *correlati*, perché gli agenti condividono lo stato del mondo: per questo il Capitolo 3 non usa mai i conteggi di record come se fossero osservazioni indipendenti. Secondo, dal punto di vista di ogni singolo agente l’ambiente è *non-stazionario* durante l’addestramento, perché le policy degli

altri cinque cambiano nel tempo — la motivazione standard del critic CTDE. La copertura parallela resta comunque una proprietà della piattaforma, identica in entrambi i regimi: parte della cornice sperimentale, non una variabile.

Percorsi per agente e seeding. A ogni reset ciascun agente riceve un percorso indipendente la cui lunghezza target è fissata dal livello attivo. La generazione è seedata deterministicamente per agente con una sequenza costruita da $\langle \text{seed traffico, contatore di reset, crc32}(\text{id agente}) \rangle$, cosicché due run lanciate con lo stesso seed sullo stesso codice vedano la stessa sequenza di estrazioni e le estrazioni siano disaccoppiate tra agenti. È questa proprietà a rendere i confronti A/B appaiati *per costruzione*, e su di essa il protocollo del Capitolo 3 fa affidamento.

Tassonomia delle terminazioni. Ogni agente termina il proprio episodio in modo indipendente con esattamente una di sei ragioni: `route_complete` (l'unico esito contato come successo); `route_short`, cioè la fine di un percorso risultato più corto del target oltre una tolleranza — un fallback degenerare che *non* conta come successo, così da prevenire l'inflazione della metrica tramite percorsi banalmente brevi; `collision`; `offroad` (il veicolo si è spostato più di 5 m dal centro della corsia più vicina); `stuck` (mancanza prolungata di progresso); e `timeout`. Ogni episodio produce quindi esattamente sei record a livello di agente.

2.3 Spazi di osservazione e azione

Ogni agente riceve un vettore di osservazione compatto e specifico per classe, con tutte le componenti normalizzate in $[-1, 1]$ e sanificate contro valori non finiti: 47 dimensioni per i veicoli, 26 per i pedoni (Tabella A.1). Tre scelte di design meritano un commento. Anzitutto, oltre alla cinematica dell'ego e dei vicini più prossimi, entrambe le classi osservano una breve *anteprima* del proprio percorso — offset relativi dei waypoint successivi nel riferimento dell'ego — insieme all'errore di heading e, per i veicoli, all'angolo della curva imminente: la geometria locale del task assegnato, senza nulla degli obiettivi altrui. In secondo luogo, una routine condivisa stima lungo il corridoio frontale un rischio di time-to-collision e una frazione di occupazione, calcolati separatamente contro i veicoli (corridoio 3.5 m, 40 m avanti, orizzonte 5 s) e contro i pedoni (3.0 m, 30 m, 4 s); gli stessi quattro valori lato veicolo sono riutilizzati dalla reward come gate di sicurezza (Sezione 2.4), così che la quantità che modula la reward sia *sempre* visibile alla policy. Infine, le ultime tre dimensioni del veicolo espongono stato interno dell'ambiente da cui la reward dipende — passi senza progresso, penalità anti-loop e tempo rimanente — senza le quali le penalità agirebbero su informazione che l'agente non può osservare, un difetto di aliasing di stato identificato e corretto durante lo sviluppo (Sezione 3.2).

Spazi di azione. Entrambe le classi usano azioni continue bidimensionali. L'azione del veicolo è $[a_{tb}, a_{steer}] \in [-1, 1]^2$, dove a_{tb} positivo mappa sull'acceleratore e negativo sul freno; quella del pedone è $[a_{speed}, a_{\Delta h}]$, con $a_{speed} \in [0, 1]$ che scala una velocità massima di camminata di 5.0 m/s e $a_{\Delta h} \in [-1, 1]$ che comanda un cambio di heading fino a $\pm 45^\circ$ per passo. Per il controllo continuo la policy è una gaussiana diagonale: il campionamento non è un dettaglio implementativo ma parte dell'oggetto appreso, un punto che diventerà concreto nella Sezione 3.3.

Osservazione globale per il critic. Durante il solo addestramento il critic riceve una concatenazione a slot fissi delle osservazioni di tutti gli agenti seguita da una maschera di vitalità: $[v_0 | v_1 | v_2 | p_0 | p_1 | p_2 | alive_6]$, cioè $3 \times 47 + 3 \times 26 + 6 = 225$ dimensioni. La maschera è necessaria perché gli agenti terminano in modo indipendente: gli slot di quelli terminati vengono mascherati anziché riusati silenziosamente. Gli actor non vedono mai questo vettore, preservando l'esecuzione decentralizzata.

2.4 Design della reward

Le reward sono per agente e identiche nei due regimi; la Tabella A.2 elenca ogni componente con trigger e ampiezza, e la forma finale è l'esito delle iterazioni guidate da gate documentate nella Sezione 3.2 — nessuna pretesa di ottimalità è attribuita ai singoli coefficienti. Per entrambe le classi il segnale dominante è un bonus sparso per waypoint raggiunto, completato da uno shaping denso proporzionale alla riduzione per passo della distanza dal waypoint successivo, con i waypoint saltati penalizzati così che il progresso non sia manipolabile con scorciatoie.

Il blocco empiricamente più delicato è lo **shaping anti-stallo condizionato all'hazard**, che contrasta l'*equilibrio difensivo* in cui un veicolo si ferma indefinitamente per evitare qualunque rischio. Tutti i suoi termini sono sospesi mentre il veicolo attende legittimamente a un semaforo rosso o giallo. Lo scalare $hazard = \max(TTC_{veh}, occ_{veh}, TTC_{ped}, occ_{ped})$ riassume il canale di anteprima della Sezione 2.3, e un booleano $safe_to_push = (hazard < 0.85)$ fa da gate ai termini di spinta: una penalità di inattività sotto 2.5 km/h; un bonus di partenza proporzionale ad acceleratore, allineamento e a un fattore di urgenza crescente con il tempo trascorso senza progresso; e uno shaping di velocità minima attorno a un target di 8 km/h. Sopra la soglia di hazard ogni incentivo di spinta scompare, quindi la policy non è mai premiata per accelerare in un corridoio rischioso; indipendentemente dal gate, una rampa di non-progresso e una penalità anti-loop rendono lo stallo prolungato e il girare in tondo strettamente non redditizi.

I pedoni, infine, guadagnano un bonus per passo mentre camminano entro una **banda di comfort** di $[1.2, 2.6]$ m/s, intenzionalmente ampia: a 2.0 m/s un pedone copre 100 m — il target del livello hard — entro l'orizzonte di 50 s. Il suo design asimmetrico (solo bonus)

e la sua interazione con il gate di hazard dei veicoli sono un caso concreto di accoppiamento tra classi, analizzato empiricamente nel Capitolo 4.

2.5 Generazione dei percorsi e livelli di difficoltà

La difficoltà è definita dalla *lunghezza target* dei percorsi per agente, con tutti gli altri parametri di scenario tenuti costanti: i tre livelli di addestramento collocano i target di veicoli e pedoni a 30 (easy), 60 (medium) e 100 m (hard), sempre su Town03 e sempre con lo stesso traffico scriptato; un quarto livello di sola valutazione (*test*) usa Town05 con target di 80 m. La configurazione definisce anche famiglie di livelli in cui la difficoltà varia per densità di traffico anziché per lunghezza, in questa tesi non usate.

I percorsi dei veicoli sono pianificati sulla topologia stradale con il global route planner di CARLA: le destinazioni candidate sono campionate attorno alla distanza target e accettate solo se la lunghezza del cammino ottimo ricade in $[0.5, 2.0] \times$ il target, con fino a 32 tentativi per reset; se nessuna sopravvive, l'ambiente ripiega su un generatore legacy a catena di waypoint. I percorsi dei pedoni sono invece catene di segmenti di marciapiede connesse attraverso attraversamenti pedonali, plasmate da due vincoli: le catene sotto $0.5 \times$ il target vengono rigettate — la stessa guardia che sostiene la retrocessione `route_short` — e gli attraversamenti per percorso sono limitati a tre, un tetto all'esposizione sulla carreggiata fissato empiricamente (Sezione 3.2). La fattibilità dei percorsi pedonali su Town03 è una *limitazione strutturale* della piattaforma — la topologia dei marciapiedi spesso non può sostenere i target nominali medium e hard — ed è analizzata nella Sezione 4.7.

2.6 I due regimi di addestramento

Il regime è la variabile indipendente dell'esperimento principale. Entrambi sono implementati dallo stesso componente manager, consultato una volta per reset per selezionare il livello; condividono le definizioni di livello della Sezione 2.5, il budget totale di 3×10^6 passi d'ambiente e ogni altro componente descritto in questo capitolo. Differiscono *solo* nella regola di selezione.

Braccio curriculum: progressione condizionata alla competenza. L'addestramento parte con il solo livello easy sbloccato. I livelli superiori si sbloccano attraverso un gate di competenza valutato su una finestra scorrevole degli ultimi 50 episodi: il tasso di successo a finestra è calcolato separatamente per la policy veicolo e per quella pedone, e il gate vincola sul *minimo* dei due — la progressione richiede che la classe più debole sia competente, non la media. Medium si sblocca a un tasso di successo a finestra di almeno il 70%, hard al 60%; la finestra deve essere piena, e una quota minima del budget deve già essere stata spesa ai livelli precedenti (20% su easy prima di medium, 28% su medium




Figura 2.2: Progressione del curriculum. Archi pieni: gate di competenza sul tasso di successo a finestra (minimo sulle due policy, finestra di 50 episodi piena) con soglie minime di quota di budget. Archi tratteggiati: cap di pressione che garantiscono la progressione entro il budget.

prima di hard). Due decisioni di design meritano giustificazione. La prima è il gating *a finestra* e non cumulativo: il tasso cumulativo è un integratore in ritardo, trascinato verso il basso dai fallimenti di avvio a freddo, e una policy può essere competente *adesso* mentre la sua media dalla nascita è ancora ben sotto soglia. La seconda sono i *cap di pressione*: se una soglia non viene mai raggiunta, il livello si sblocca comunque una volta consumata una quota fissa del budget (30% per medium, 70% per hard), così che il braccio curriculum non possa **stallare terminalmente** su easy. Una volta sbloccati, i livelli sono campionati con pesi che normalizzano a 0.30/0.35/0.35, e quelli appena sbloccati passano per una breve fase di *probation* a pressione ridotta (Figura 2.2).

Braccio batch: alternanza stratificata. Il braccio mixed-batch è il *controllo senza ordinamento*: tutti e tre i livelli sono disponibili dal primo episodio, campionati per mescolamento stratificato senza reinserimento con finestra tre — ogni finestra consecutiva di tre episodi è una permutazione uniformemente casuale di {easy, medium, hard}. Ne risulta esposizione uniforme 1/3 con sbilanciamento massimo di un episodio per campionatore, evitando sia la deriva del campionamento i.i.d. sia qualunque ordinamento deterministico fisso.

Sotto questa costruzione i due bracci consumano lo stesso budget sulla stessa distribuzione di task in attesa; ciò che differisce è *quando* ogni parte di quella distribuzione viene presentata, e se la presentazione è condizionata alla competenza misurata. Qualunque differenza comportamentale è quindi attribuibile alla politica di ordinamento, a meno della varianza da run a run — quantificata nella Sezione 3.2 e discussa nella Sezione 4.10.

2.7 Encoder del critic, ottimizzazione e valutazione

Nella configurazione di default il critic centralizzato è un MLP che mappa l’osservazione globale a 225 dimensioni attraverso due strati nascosti da 256 unità verso un valore scalare. L’asse sperimentale secondario sostituisce questo encoder con uno su grafo, mentre *entrambi gli actor restano gli identici MLP* della Sezione 2.1: qualunque differenza comportamentale

tra le due varianti è quindi attribuibile alla stima del valore durante l’addestramento e non alla capacità della policy, e a tempo di esecuzione le due varianti sono indistinguibili. L’encoder GNN riseziona l’osservazione globale nei sei slot per agente, proietta ciascuno attraverso uno strato lineare per classe in un embedding di nodo a 64 dimensioni e applica due round di message passing con aggregazione a media in stile GraphSAGE [12]: ogni nodo combina il proprio embedding con la media degli embedding degli altri agenti *vivi*, e un mean-pool mascherato produce l’input della testa di valore. La maschera di vitalità guida aggregazione e pooling, così che gli agenti terminati escano dal riassunto del critic invece di contribuire slot stantii. La codebase fornisce anche un encoder ad attenzione e la normalizzazione PopArt dietro flag; entrambi restano disabilitati in tutta questa tesi.

Ottimizzazione. Tutte le run della campagna condividono la stessa configurazione, byte-identica tra i bracci salvo i flag di regime ed encoder: learning rate 5×10^{-4} ; $\gamma = 0.997$; GAE $\lambda = 0.95$; clip PPO $\varepsilon = 0.2$ con penalità KL aggiuntiva; batch di addestramento 8.000 passi, minibatch 256, 15 epoche SGD per batch. Il coefficiente di entropia segue uno schedule da 0.03 a 0.005 ancorato all’83% del budget, espresso come frazione così che run diagnostiche brevi e run complete attraversino lo stesso profilo di esplorazione. La configurazione completa è nell’Capitolo C.

Pipeline di valutazione. I risultati sono misurati a tre livelli, tutti calcolati dai record a livello di agente. Il *flusso di addestramento* fornisce le metriche cumulative su tutti gli episodi: sono on-policy e, nel braccio curriculum, calcolate su un mix di livelli che cambia nel tempo, quindi caratterizzano il processo di addestramento e non l’abilità finale. Il *ricalcolo statico* è un passaggio offline che ricalcola gli aggregati da disco, deduplica i record e verifica l’integrità. La *valutazione finale del checkpoint* ricarica il modello addestrato e lo esegue su quattro scenari fissi da 100 episodi ciascuno — easy, medium e hard su Town03, più il livello test su Town05 — ed è l’unico confronto a distribuzione appaiata tra i bracci; gli episodi sono valutati con la policy *stocastica*, con re-seeding per episodio dello scenario e del campionatore di azioni, perché valutare la media deterministica collapserebbe la policy su una singola traiettoria per scenario (Sezione 3.3).

Capitolo 3

Il progetto — metodo e campagna

La piattaforma del Capitolo 2 non è stata progettata in un solo passaggio: è il prodotto di una campagna iterativa in cui ogni modifica doveva superare un gate quantitativo predefinito prima di entrare nel trunk. Questo capitolo documenta le regole di misura (Sezione 3.1), il protocollo di gate con il registro delle iterazioni (Sezione 3.2), i difetti di validità trovati e corretti lungo il percorso (Sezione 3.3) e il design della campagna di confronto finale (Sezione 3.4).

3.1 Metriche e regole di misura

Unità di misura e integrità. L'unità di analisi è il *record a livello di agente*: una voce JSON per agente per episodio, sei per episodio. Tutti gli aggregati sono calcolati dopo deduplica per identificatore di episodio e di agente — in valutazione lo scenario fa parte della chiave. Due condizioni di integrità sono imposte prima che qualunque numero venga riportato: esattamente sei record per episodio, e nessun valore non finito. Una run che fallisce una delle due non viene analizzata oltre.

Criterio di successo rigoroso. Un agente ha successo se e solo se la sua ragione di terminazione è `route_complete`; in particolare `route_short` — raggiungere la fine di un percorso degenerare troppo corto — *non* è successo. La regola è stata messa alla prova durante lo sviluppo, dove una modifica che contava `route_short` come successo è stata introdotta e poi revertita, mantenendo il criterio rigoroso al costo di numeri assoluti più bassi. È un pregio, non un difetto: lontano dal pavimento e dal soffitto la metrica conserva spazio per muoversi in entrambe le direzioni.

Tre viste di reporting. Ogni risultato è riportato per veicoli e pedoni separatamente, più una vista combinata: le due classi hanno task, spazi di azione e limiti strutturali diversi, e il registro mostra effetti di regime che esistono per una sola classe. Il successo congiunto a livello di episodio non è mai usato, perché con agenti correlati compone i

Tabella 3.1: Catalogo delle metriche. Tutti i tassi sono quote dei record a livello di agente.

Metrica	Definizione
Tasso di successo (SR)	record con <code>route_complete</code>
Collisione / offroad Stuck / timeout	record con <code>collision</code> / <code>offroad</code> (offroad solo veicoli) record troncati con completamento < 0.3 o loop attivo / con completamento ≥ 0.3 ; la somma $s+t$ è il target primario anti-stallo
Completamento / efficienza di percorso	frazione di waypoint consumati; lunghezza ottima completata su distanza percorsa, con tetto a 1 e valore 0 per i record stuck
Velocità media	km/h per i veicoli, m/s per i pedoni
Diagnostica dei percorsi	quote di sorgente, flag under-target e too-short, attraversamenti, passi di non-progresso

fallimenti in modo moltiplicativo e nasconde la struttura di classe. I valori cumulativi sono l'aggregazione primaria, il successo a finestra scorrevole è usato solo dal gate del curriculum, e la dinamica entro la run è mostrata dividendo l'addestramento in quartili (Q1–Q4). La Tabella 3.1 definisce le metriche usate nel Capitolo 4.

3.2 Protocollo di sviluppo guidato da gate

La varianza da run a run in questo ambiente è grande e il budget di calcolo non permetteva di replicare ogni modifica candidata. Il protocollo adottato in risposta ha quattro regole. **(1) Una manopola alla volta:** ogni candidato è un diff stretto e isolato comportamentalmente — un singolo termine di reward, una singola soglia, un singolo gruppo di osservazioni. **(2) A/B appaiato a budget diagnostico fisso:** ogni candidato gira per 3×10^5 passi contro la baseline corrente del trunk, con lo stesso seed e — grazie al seeding deterministico dei percorsi (Sezione 2.2) — una sequenza di percorsi appaiata per costruzione; le run di sviluppo erano bloccate su easy salvo quando il candidato riguardava il curriculum stesso. **(3) Un gate quantitativo predefinito:** per le modifiche orientate ai veicoli il candidato è promosso solo se, rispetto alla baseline appaiata, l'SR veicoli migliora di almeno +2.0 pp, stuck+timeout migliora di almeno −2.0 pp, collisione e offroad peggiorano ciascuno di non più di +1.0 pp, ed entrambe le condizioni di integrità valgono; le modifiche che toccano macchinari condivisi portano una condizione laterale *must-not-collapse* sull'altra classe, e un gate fallito significa revert. **(4) Meccanismo ed esito registrati separatamente:** il registro annota se il meccanismo inteso si è verificato e se il gate comportamentale è passato — i due spesso dissentono, e alcune manopole che hanno fallito il gate sono state consapevolmente mantenute, con l'ipotesi registrata come falsificata, perché revertirle avrebbe ripristinato un difetto o perché il fallimento stesso era informativo.

Lo sviluppo è proceduto in sei fasi; il registro completo dei candidati è nell’Capitolo B. Un *pilota architetturale* di nove run (aprile 2026) ha incrociato encoder del critic e regimi nell’era pre-correzioni: i dati erano integri, ma i veicoli restavano a un tasso di successo prossimo a zero (0.2–3.9%) in ogni cella, rendendo il confronto non informativo e reindirizzando lo sforzo verso la validità dell’ambiente. Sono seguite una fase di *correttezza*, una di *osservabilità* (feature veicolo consapevoli del percorso, poi l’estensione a 47D che chiude il gap di aliasing di stato), una sequenza di *iterazioni su ottimizzatore e reward* dagli esiti misti, una fase sull’*accoppiamento tra classi* — pedoni più veloci saturano il canale di hazard dei veicoli e possono spingerli in un equilibrio difensivo a velocità zero attraverso il gate `safe_to_push`, risolto alzandone la soglia da 0.75 a 0.85 — e infine la *meccanica del curriculum*, con l’ultima modifica entrata nel trunk prima della campagna: il tetto agli attraversamenti pedonali portato da otto a tre.

Un ultimo dato di questa fase è il metro di tutta la tesi. Tre repliche a lunghezza piena (3×10^6 passi) dell’*identico* trunk pre-campagna, con codice, configurazione e seed byte-identici, hanno prodotto tassi di successo cumulativi dei veicoli tra 52.2 e 62.4%: CARLA sotto carico multi-agente non è deterministico da run a run nemmeno in modalità sincrona con tutti i seed fissati. Questa banda di ~ 10 pp è il riferimento contro cui ogni effetto del Capitolo 4 viene letto, e motiva sia il design appaiato sia la cautela attribuita ai delta a replica singola.

3.3 Validità dell’ambiente: bug trovati e corretti

In una piattaforma multi-agente custom l’apparato di misura è parte dell’esperimento. Tre episodi durante lo sviluppo hanno prodotto apparenti effetti di policy che erano in realtà artefatti; sono riportati qui sia perché hanno plasmato il protocollo finale, sia perché le loro firme di rilevamento possono essere utili ad altri.

Lunghezza dei percorsi: un cambio di distribuzione dei task. Il route planner poteva emettere percorsi molto più lunghi del target di livello, quindi episodi nominalmente “easy” spesso non erano facili. Imporre i limiti $[0.5, 2.0] \times$ il target (Sezione 2.5) ha spostato l’SR cumulativo di addestramento dei veicoli di $\approx +50$ pp *senza alcuna modifica alla policy o alla reward*, e il pavimento dei veicoli del pilota di aprile è stato poi ricondotto proprio a questo difetto. È l’evidenza interna più forte per una regola usata in tutta la tesi: *mai confrontare numeri assoluti tra versioni dell’ambiente; ancorare le affermazioni a contrasti appaiati entro una versione*.

Seeding dei percorsi: appaiamento rotto. I seed dei percorsi per agente derivavano originariamente dalla `hash()` built-in di Python, che è salata per processo: due run nominalmente identiche estraevano sequenze di percorsi *diverse*, degradando silenziosa-

mente ogni confronto A/B. La correzione deriva i seed da una **SeedSequence** esplicita (Sezione 2.2); la lezione è che l'appaiamento va costruito e verificato, non assunto.

Pipeline di valutazione: collasso della misura. La prima valutazione di checkpoint ha restituito un tasso di successo esattamente del 33.33% in *ogni* scenario: uno dei tre veicoli a completare, ogni episodio. Questo pattern troppo pulito per essere vero ha esposto quattro difetti accoppiati: il seed di scenario per episodio era costante, quindi ogni episodio rigiocava la stessa configurazione di traffico; la policy era valutata sulla sua media deterministica, collassando la gaussiana su una singola traiettoria; il sottoprocesso non inizializzava mai il logger; e il seed torch era costante tra i sottoprocessi. Tutti e quattro sono stati corretti e il protocollo stocastico della Sezione 2.7 è diventato lo standard; nessuna di queste correzioni tocca l'addestramento, e nessuna affermazione di policy è derivata da esse. La lezione generale: la validità della misura va stabilita *prima* del tuning, e risultati implausibilmente regolari sono un segnale di rilevamento, non una buona notizia.

3.4 Design della campagna finale

L'esperimento finale è un fattoriale 2×2 — {encoder del critic MLP, GNN} $\times$ {curriculum, mixed-batch} — di quattro run da 3×10^6 passi ciascuna, tutte sullo stesso trunk congelato, con un unico seed (999) appaiato tra le quattro celle e la difficoltà definita dalla lunghezza del percorso. Le configurazioni sono byte-identiche tra le celle salvo i due flag sperimentali. Il design era originariamente dimensionato a tre seed appaiati per cella; l'asse di replicazione è stato eliminato per ragioni di budget di calcolo, poiché ogni run occupa l'unica macchina disponibile per circa due giorni (Capitolo D). La riduzione è dichiarata qui anziché nascosta: con un seed per cella, ogni contrasto del Capitolo 4 è un *caso di studio appaiato*, non la stima di una distribuzione.

Contrasti. Il contrasto primario è curriculum contro mixed-batch *entro* architettura, ed è osservato *due volte* — una per ciascuna architettura del critic, addestrata indipendentemente — quindi la replicazione tra architetture sostituisce in parte quella sui seed: un effetto che compare con lo stesso segno in entrambe le coppie è molto più difficile da attribuire al rumore di quanto lo sarebbe un contrasto singolo. Il contrasto secondario è critic MLP contro GNN *entro* regime; la lettura dell'interazione (H3) è solo direzionale a questa dimensione campionaria. Nessuna inferenza statistica formale è rivendicata: gli effetti sono letti contro la banda delle repliche a seed identico della Sezione 3.2.

La campagna *non* mette invece alla prova: famiglie di difficoltà basate sulla densità di traffico o su assi misti; l'encoder del critic ad attenzione e la normalizzazione PopArt (disponibili, disabilitati); architetture degli actor (sempre MLP); ablazioni del numero di agenti (sempre $3 + 3$); o coppie di mappe oltre Town03 $\rightarrow$ Town05.

Capitolo 4

Il progetto — risultati e discussione

Questo capitolo riporta i risultati della campagna lungo i quattro assi di confronto, aggiunge l’asse architetturale, chiude con i verdetti sulle tre ipotesi e ne discute il significato. Tutti i numeri sono ricalcolati dai record a livello di agente su disco secondo le regole della Sezione 3.1.

4.1 Integrità della campagna

Le quattro run sono state lanciate sullo stesso trunk con seed 999, e i diff di configurazione confermano che le celle differiscono solo nei flag di regime ed encoder del critic. Tutti e otto i log — quattro di addestramento e quattro di valutazione — superano ogni condizione di integrità della Sezione 3.1: esattamente sei record per episodio, zero righe malformate, zero valori non finiti. Le run hanno prodotto tra 3.168 e 3.293 episodi ciascuna, poco più di 19.000 record; l’unica anomalia a registro è benigna, poiché la valutazione GNN-curriculum ha mantenuto 401 episodi dopo la deduplica, uno spostamento di peso dello 0.25% senza effetto alla precisione riportata. L’esposizione di livello realizzata rispecchia infine i due design: entrambe le run batch restano entro ≈ 2 punti percentuali dall’uniforme 1/3, con tutti e tre i livelli presenti entro i primi venti episodi, mentre le run curriculum concentrano l’esposizione su easy e medium all’inizio e raggiungono hard solo dopo i rispettivi sblocchi, chiudendo a 32.5/45.8/21.6% (MLP) e 32.4/37.4/30.1% (GNN).

4.2 Efficienza campionaria

Una avvertenza va premessa alla Figura 4.1: ogni curva è misurata sul *mix di livelli concorrente* della propria run — gated per le celle curriculum, uniforme per batch — quindi i confronti verticali tra bracci non sono omogenei finché il curriculum non ha sbloccato tutti i livelli.




Figura 4.1: Tasso di successo a finestra (100 episodi) rispetto ai passi d’ambiente, tutte e quattro le celle.

Fase iniziale: decollo indistinguibile. Tutte e quattro le celle salgono alla stessa velocità. L’SR veicoli a finestra di 100 episodi supera per la prima volta il 30% dopo 137–142K passi e il 50% dopo 162–175K passi *in ogni cella* — uno scarto sotto l’8%, ben dentro il rumore. La parte notevole è *su che cosa* ciascuna policy ha superato quelle soglie: le celle curriculum su esposizione solo-easy, le celle batch sul mix uniforme completo, percorsi da 100 m inclusi. A parità di budget, il decollo iniziale non è stato il fattore discriminante tra i regimi.

Tempi di sblocco. Medium si è sbloccato praticamente nello stesso punto in entrambe le run curriculum (al 26.1% degli episodi in entrambe). Hard, invece, si è sbloccato molto prima sotto il critic GNN: al 58.0% dell’addestramento contro il 71.0% per MLP — quest’ultimo coerente con lo scatto del cap di pressione al 70% del budget più che con il gate di competenza, mentre la cella GNN ha raggiunto il gate hard *per competenza*, e ha quindi visto $\approx 40\%$ episodi hard in più. Da $\approx 0.5\text{M}$ passi, infine, le curve batch si assestano sotto le due curve curriculum, che si seguono da vicino; tutte derivano poi verso il basso a fine addestramento (Sezione 4.4).

4.3 Prestazione finale

Il contrasto primario, coppia MLP. Nella valutazione finale a distribuzione appaiata (Tabella 4.1, pannello inferiore) la policy veicolo addestrata a curriculum completa il 48.33% dei percorsi contro il 29.83% del batch: +18.5 punti percentuali, con lo stesso segno in *tutti e quattro* gli scenari (+19.0, +20.7, +15.3, +19.0 pp) e nel cumulativo di addestramento (+11.0 pp). Il margine è circa da due a quattro volte la banda delle repliche a seed identico della Sezione 3.2, e la sua coerenza tra scenari, livelli di difficoltà e strati di misura è ciò che il design appaiato può offrire al posto della replicazione dei seed.

Tabella 4.1: I due strati di misura. Sopra: metriche cumulative di addestramento. Sotto: valutazione finale del checkpoint, 400 episodi per cella (401 per GNN-curriculum, Sezione 4.1), l'unico confronto a distribuzione appaiata tra i bracci. Valori a livello di agente in %; velocità in km/h (veicoli) e m/s (pedoni).

Cella	Veicoli					Pedoni		
	SR	s+t	coll.	off.	vel.	SR	s+t	vel.
MLP-curr.	57.28	30.48	8.84	3.41	10.2	56.59	42.56	1.96
MLP-batch	46.31	23.61	17.33	12.76	18.7	57.06	42.03	1.61
GNN-curr.	56.55	20.84	13.37	9.23	18.0	60.50	38.58	1.91
GNN-batch	49.41	22.75	17.56	10.28	26.6	58.03	41.11	1.45

Cella	SR veicoli per scenario					Veicoli, compl.			Ped.
	easy	med.	hard	test	tutti	s+t	coll.	off.	SR
MLP-curr.	60.33	51.67	44.33	37.00	48.33	38.25	10.42	3.00	47.00
MLP-batch	41.33	31.00	29.00	18.00	29.83	31.17	26.00	13.00	48.92
GNN-curr.	52.48	42.33	36.00	35.67	41.65	25.10	22.94	10.31	59.02
GNN-batch	55.67	42.00	33.33	25.67	39.17	23.83	26.92	10.08	48.67

Scenari easy/medium/hard su Town03, *test* su Town05.

Due modi diversi di fallire. I regimi producono guide riconoscibilmente diverse (Figura 4.2). La policy batch è quasi due volte più veloce (18.7 contro 10.2 km/h in addestramento) ma converte quella mobilità in contatto: collisione 17.3% contro 8.8% e offroad 12.8% contro 3.4% in addestramento, che si allargano a 26.0% contro 10.4% di collisione in valutazione. La policy curriculum fallisce invece principalmente per stallo (stuck+timeout 38.3% contro 31.2% in valutazione). Nessun profilo domina l'altro su ogni asse — il curriculum scambia velocità per sicurezza — ma sul criterio di successo rigoroso lo scambio si risolve chiaramente a suo favore. I pedoni, per contro, sono *piatti* tra i bracci ovunque, entro ± 6 pp in ogni scenario: il regime, in questa piattaforma, è una variabile della policy *veicolo*, e la struttura dei fallimenti pedonali è ripresa nella Sezione 4.7.

Le celle GNN a colpo d'occhio. In addestramento la cella GNN-curriculum atterra entro il rumore di MLP-curriculum sull'SR principale (56.55 contro 57.28%) ma ridistribuisce la massa dei fallimenti: meno stallo (-9.6 pp), più contatto e velocità molto più alta (18.0 contro 10.2 km/h) — più vicina alla mobilità delle celle batch, con il successo di una cella curriculum. GNN-batch spinge le stesse tendenze oltre (26.6 km/h, la cella più veloce) *battendo* al contempo MLP-batch di $+3.1$ pp in addestramento e $+9.3$ pp in valutazione: l'encoder del critic plasma il profilo di rischio e interagisce con il regime (Sezione 4.6).




Figura 4.2: Composizione delle terminazioni dei veicoli per cella, in addestramento (cumulativo) e alla valutazione finale. Le due grammatiche del fallimento sono visibili a colpo d’occhio: dominata dallo stallo in MLP-curriculum, dominata dal contatto nelle celle batch, con le celle GNN in posizione intermedia.

Tabella 4.2: SR veicoli per quartile di addestramento (%). Sopra: tutti i livelli (confuso dal mix per le celle curriculum). Sotto: solo episodi easy, controllato per livello (easy resta $\approx 30\%$ del mix dopo gli sblocchi). $\Delta = Q4 - Q1$.

Cella	Q1	Q2	Q3	Q4	Δ
<i>Tutti i livelli</i>					
MLP-curr.	68.9	61.1	54.4	44.7	-24.2
MLP-batch	58.7	45.9	41.8	38.7	-20.0
GNN-curr.	66.6	62.2	54.5	42.9	-23.7
GNN-batch	50.5	54.6	47.5	45.1	-5.4
<i>Solo livello easy</i>					
MLP-curr.	68.9	69.3	59.6	52.4	-16.5
MLP-batch	64.2	52.0	48.9	45.6	-18.6
GNN-curr.	66.6	67.9	56.1	55.8	-10.8
GNN-batch	59.7	62.8	54.3	53.3	-6.4

4.4 Dinamica entro la run

Ogni curva della Figura 4.1 deriva verso il basso dopo il picco iniziale. Per le celle curriculum questo è in parte meccanico — il mix concorrente si indurisce a ogni sblocco — quindi la Tabella 4.2 separa i due effetti: il pannello superiore riporta le traiettorie per quartile complessive, quello inferiore la traiettoria *sui soli episodi easy*, dove il task è costante per costruzione.

Erosione, non solo indurimento del mix. Il pannello controllato per livello mostra che l’indurimento del mix *non* è tutta la storia: la prestazione a livello easy si erode entro ogni run, da -6.4 pp (GNN-batch, la cella più stabile) a -18.6 pp (MLP-batch). Le celle batch rendono il caso in modo pulito, perché la loro distribuzione dei task è costante e il

loro declino è quindi interamente degradazione entro la run; i pedoni si erodono ancora di più, fino a -31.8 pp. Due meccanismi candidati sono compatibili con i dati e non separabili a $n=1$: la co-adattazione tra classi, poiché il comportamento dei pedoni degrada in parallelo e alimenta il canale di hazard dei veicoli, e l’annealing dell’entropia — che però si completa solo dentro Q4, mentre l’erosione inizia già in Q3, e non può quindi esserne l’unica causa. La conclusione pulita è architetturale: sotto il critic GNN l’erosione è dimezzata o meglio, qualunque ne sia il driver.

Due grammatiche del fallimento, un attrattore comune. La velocità media ordina le quattro celle — 10.2 (MLP-curr.), 18.0 (GNN-curr.), 18.7 (MLP-batch), 26.6 km/h (GNN-batch) — e i fallimenti da contatto seguono lo stesso ordine, mentre lo stallo anti-correla. Ciò che *non* varia è la struttura interna dello stallo: in tutte e quattro le celle le terminazioni stuck si decompongono quasi identicamente e i passi medi di non-progresso coprono una banda stretta. Regimi e critic cambiano *quanto* una policy stalla, non *come* stalla. Coerentemente, il profilo lento-e-in-stallo appartiene a esattamente una cella, MLP-curriculum: la sua gemella sotto il critic GNN è quasi due volte più veloce con un terzo di stallo in meno, allo stesso SR principale. L’equilibrio cauto documentato durante lo sviluppo (Sezione 3.2) non è dunque una proprietà dell’addestramento a curriculum in quanto tale, ma un bacino in cui la run con critic MLP si è assestata e quella con critic GNN no: il regime da solo non determina l’equilibrio.

4.5 Generalizzazione: da Town03 a Town05

Lo scenario test colloca le stesse policy su Town05 — layout a griglia quadrata e più corsie, strutturalmente diverso da Town03 — per 100 episodi con target di 80 m e traffico come in addestramento.

L’ordinamento sopravvive al cambio di mappa. Il curriculum completa il 37.0% dei percorsi su Town05 contro il 18.0% del batch (+19.0 pp): essenzialmente lo stesso margine in-domain. Il calo assoluto dalla media degli scenari Town03 è quasi identico per i due bracci (-15.1 contro -15.8 pp), quindi il vantaggio del curriculum non è un’idiosincrasia di Town03: si trasferisce per intero su strade mai viste. Letta contro H2, la copertura iniziale più ampia del regime batch non gli ha comprato *alcun* vantaggio di generalizzazione — semmai il calo relativo è peggiore, dalla sua base più bassa (-47% contro -29%). Ogni braccio, inoltre, fallisce su Town05 nel modo in cui fallisce a casa, solo di più: la policy curriculum stalla (stuck+timeout 50.7%), la policy batch si schianta (collisione 37.3%).

Sotto il critic GNN il vantaggio esiste *solo* fuori distribuzione. La coppia GNN affila il punto. In-domain i due bracci sono gemelli statistici — SR veicoli medio sugli




Figura 4.3: SR veicoli: media degli scenari Town03 contro test Town05, per cella. Le celle curriculum calano meno; la coppia GNN è indistinguibile in-domain (43.6 contro 43.7%) e si separa di 10 pp sulla mappa mai vista.

Tabella 4.3: L’interazione architettura×regime: SR veicoli curriculum-meno-batch (pp) per strato di misura, entro ciascuna architettura. Il delta di valutazione dei pedoni è aggiunto per completezza.

$\Delta(\text{curr.} - \text{batch})$	Coppia MLP	Coppia GNN
Cumulativo di addestramento (veic.)	+10.97	+7.14
Valutazione complessiva (veic.)	+18.50	+2.48
Valutazione, media Town03 (veic.)	+18.33	−0.06
Valutazione, Town05 (veic.)	+19.00	+10.00
Valutazione complessiva (ped.)	−1.92	+10.35

scenari Town03 43.6% (curriculum) contro 43.7% (batch) — eppure su Town05 si separano di +10.0 pp (35.7 contro 25.7%), con il calo più piccolo di ogni cella per GNN-curriculum (−7.9 pp) contro −18.0 pp per GNN-batch. Dove la coppia MLP mostrava un vantaggio del curriculum che *si trasferisce*, la coppia GNN ne mostra uno che *compare* solo nel trasferimento: evidenza con lo stesso segno, veicolata da due firme diverse. I pedoni, infine, si trasferiscono con facilità — ≈ 30 pp sopra i risultati hard di entrambi i bracci su Town03 — indicando ancora la fattibilità dei percorsi, non la generalizzazione della policy, come loro collo di bottiglia (Sezione 4.7).

4.6 Asse architetturale: critic MLP contro GNN

L’asse secondario sostituisce solo l’encoder del critic; actor, reward, ambiente e budget sono identici, quindi le differenze tra celle MLP e GNN misurano come la *stima del valore* plasma ciò che gli stessi actor apprendono.

L’effetto di regime dipende dal critic. La Tabella 4.3 condensa il risultato centrale della campagna. Sotto il critic MLP il curriculum batte il batch con un margine ampio e coerente tra gli strati; sotto il critic GNN lo stesso contrasto quasi svanisce, con +2.5 pp complessivi in valutazione — dentro la banda di rumore a seed identico — ed esattamente zero in-domain. L’unica componente del vantaggio del curriculum che *si replica in entrambe le architetture* è quella out-of-distribution: +19.0 pp (MLP) e +10.0 pp (GNN) su Town05. H3 è quindi supportata nella sua forma forte: l’encoder del critic cambia non solo l’entità, ma il *luogo* dell’effetto di regime.

Da dove viene l’interazione. La compressione è prodotta da due effetti architetturali asimmetrici, uno per regime. Entro il batch il critic GNN *aiuta*: +3.1 pp in addestramento e +9.3 pp in valutazione rispetto a MLP-batch, con la dinamica entro la run più stabile della campagna. È coerente con il meccanismo che motiva i critic CTDE in primo luogo: sotto una distribuzione mista con sei agenti interagenti, la stima strutturata del valore dovrebbe aiutare di più dove il segnale è più rumoroso, cioè il regime batch dal passo 0. Entro il curriculum, invece, il critic GNN *rimodella* più che migliorare: evita l’equilibrio difensivo, sblocca hard per competenza anziché per cap di pressione, vede $\approx 40\%$ episodi hard in più — e converte tutto questo in mobilità e contatto anziché in successo (SR −6.7 pp rispetto a MLP-curriculum). I pedoni mostrano l’interazione speculare: il critic GNN li solleva sotto curriculum (+12.0 pp in valutazione, la miglior cella pedoni della campagna al 59.0%) ma non sotto batch.

Il pattern è internamente coerente su quattro strati di misura ed entrambe le classi di agenti, ma le sue grandezze portano la consueta qualifica $n=1$ (Sezione 4.10): il delta complessivo di +2.5 pp della coppia GNN esplicitamente *non* è rivendicato come vantaggio del curriculum, e il risultato rivendicato è il suo contrasto con la coppia MLP più la componente Town05 replicata tra le architetture.

4.7 Limiti strutturali dei pedoni

I risultati dei pedoni vanno letti contro un vincolo che nessun regime di addestramento può rimuovere: la topologia dei marciapiedi di Town03 spesso non può fornire il task nominale. Le diagnostiche di generazione dei percorsi pedonali sono infatti statisticamente indistinguibili tra le quattro celle — percorsi under-target 55.1–55.9% dei record, flag too-short 7.9–9.2%, percorsi da respawn 13.4–14.1% — e questa *invarianza* è il punto: sono proprietà della mappa e del planner, non delle policy, e fissano quindi un soffitto comune a ogni cella.

L’SR pedoni cala poi monotonicamente con il livello in ogni cella (in addestramento easy 70–83%, medium 53–60%, hard 29–44%) e la valutazione a distribuzione appaiata riproduce il gradiente. Un collasso che sopravvive a due architetture, due regimi e due

Tabella 4.4: Ipotesi contro evidenza (contrasti appaiati, $n=1$ per cella; delta in pp di SR veicoli salvo diversa indicazione).

Ipotesi	Predizione	Verdetto	Evidenza
H1 (curriculum)	migliore efficienza campionaria <i>iniziale</i>	rigettata	decollo identico nelle quattro celle (50% a 162–175K passi)
	prestazione finale più alta	supportata sotto MLP, non sotto GNN in-domain	+18.5 (MLP) contro +2.5 (GNN) in valutazione
	rischio di plateau od oblio su hard	rimodellato	erosione tardiva reale ma <i>di piattaforma</i> : $\Delta Q1 \rightarrow Q4$ per livello da -6 a -19 pp
H2 (batch)	piena copertura dal passo 0	confermata (meccanica)	tutti i livelli entro i primi 20 episodi
	segnale iniziale più rumoroso	non visibile	stesso decollo, sul mix più difficile
	copertura $\rightarrow$ robustezza su mappa nuova	rigettata	calo su Town05 uguale o peggiore in entrambe le coppie (-15.8/-18.0 contro -15.1/-7.9 pp)
H3 (interazione)	l'effetto di regime può dipendere dall'encoder del critic	supportata (forma forte)	effetto in-domain +18.3 (MLP) contro -0.1 (GNN); solo la componente Town05 si replica

strati di misura mentre le diagnostiche restano costanti è guidato dalla geometria del task, e il controfattuale Town05 rende concreta l'attribuzione: con target di 80 m l'SR pedoni balza a 54–71% in ogni cella, da 15 a 31 pp *sopra* il risultato hard su Town03 e per giunta su una mappa mai vista — se il collasso fosse un limite di policy, strade nuove dovrebbero nuocere, non aiutare. Entro l'inviluppo di fattibilità le differenze di policy restano comunque visibili, e una cella si separa dal gruppo in valutazione (GNN-curriculum, 59.0% contro 47–49% altrove). La conseguenza metodologica resta però vincolante: i tassi di successo medium e hard dei pedoni non sono una misura pulita della qualità della policy, quindi la tesi confronta i pedoni solo entro livello e tra bracci.

4.8 Verdicti sulle ipotesi

Due cose sopravvivono a ogni cella, ogni strato ed entrambe le architetture: il vantaggio del curriculum sulla mappa mai vista, e il ruolo del regime come variabile della policy *veicolo* che rimodella la composizione dei fallimenti. Ciò che non è sopravvissuto è l'aspettativa

popolare da entrambi i lati: il curriculum non ha appreso più in fretta all’inizio, e la copertura più ampia del batch non ha comprato robustezza.

4.9 Discussione

Non la velocità di apprendimento, ma la selezione dell’equilibrio. L’asse su cui i curricula sono classicamente attesi ripagare non ha mostrato nulla. Una lettura plausibile è che il design della reward di questa piattaforma risolva già il problema per cui i curricula vengono di solito ingaggiati: con bonus densi per waypoint e shaping sulla distanza (Sezione 2.4), anche i percorsi da 100 m forniscono segnale di apprendimento fin dai primi episodi, quindi i task facili non servono per l’avvio. È una *condizione di scope* su H1, più che una confutazione del curriculum learning in generale. Ciò che l’ordinamento ha cambiato è *quale policy lo stesso apprendista è diventato*, e la meccanica è visibile nei vincoli: completare un percorso da 100 m entro l’orizzonte di mille passi richiede una velocità media sana, quindi una policy esposta ai percorsi hard dal passo 0 deve guidare veloce per riuscire del tutto — e paga in collisioni — mentre una policy che spende il suo primo quarto di addestramento su percorsi da 30 m può riuscire lentamente, e cementa la cautela. L’ordinamento agisce dunque da *selettore di equilibri* sul trade-off velocità–sicurezza più che da acceleratore, e le celle GNN sostengono la lettura dall’altro lato: con uno stimatore di valore diverso lo stesso curriculum ha selezionato un equilibrio più veloce. Va infine osservato che l’erosione entro la run è di piattaforma e che l’ordinamento non la causa né la previene: i numeri cumulativi *finali* sottostimano i picchi di metà addestramento in ogni configurazione, e la selezione del checkpoint cambierebbe le conclusioni.

Generalizzazione: il beneficio portabile. L’unico vantaggio replicato in entrambe le architetture è il margine su Town05, ottenuto *nonostante* la copertura in-domain più ampia del batch. Un meccanismo provvisorio è coerente con entrambe le coppie: la policy batch si co-adatta per l’intero budget a una singola distribuzione stazionaria, mentre la policy curriculum deve restare competente attraverso una sequenza *mutevole* di distribuzioni — una forma blanda di regolarizzazione implicita per non-stazionarietà. A $n=1$ per cella questa resta un’ipotesi; ciò che i dati stabiliscono è la direzione e la sua replicazione tra architetture.

La copertura parallela dei task rivisitata. La cornice a mondo condiviso è stata adottata per il throughput, con campioni correlati e non-stazionarietà reciproca accettati come costi; col senno di poi la campagna mostra quei “costi” fare lavoro scientifico di prim’ordine. L’equilibrio difensivo esiste *solo* perché le reward dei veicoli sono condizionate a un canale di hazard alimentato dal comportamento dei pedoni, e il risultato architetturale punta nella stessa direzione: sostituire un critic piatto con uno che modella gli agenti

come nodi interagenti ha cambiato gli esiti in ogni cella, cosa impossibile se la struttura tra agenti fosse trascurabile. In assenza di un controllo a un agente per mondo, però, il beneficio di throughput resta un argomento di design e non una misura.

4.10 Minacce alla validità e limiti di scope

Non-determinismo del simulatore e dimensione campionaria. La minaccia dominante è quantificata anziché assunta: tre run a lunghezza piena con codice, configurazione e seed byte-identici hanno prodotto tassi di successo cumulativi dei veicoli tra 52.2 e 62.4% (Sezione 3.2). Ogni effetto è letto contro questa banda di ~ 10 pp, e le differenze al suo interno non sono mai attribuite a un fattore sperimentale. A ciò si somma il fatto che ogni cella contiene una sola run (Sezione 3.4): l'appaiamento dei seed rende i contrasti internamente puliti, e il contrasto primario porta con sé una replicazione incorporata perché è osservato sotto entrambe le architetture, ma nessuna inferenza statistica formale è possibile a questo n , e nessuna è rivendicata.

Rumore di valutazione, reward e mappe. In valutazione, 100 episodi per scenario significano 300 record veicolo: a tassi di fascia media il solo errore standard binomiale è ≈ 3 pp per scenario, quindi le differenze di pochi punti a livello di singolo scenario non sono individualmente significative e si interpretano solo i pattern tra scenari. La funzione di reward, inoltre, è stata calibrata attraverso iterazioni eseguite per lo più su configurazioni bloccate su easy, quindi lo shaping del trunk può essere implicitamente sbilanciato verso i percorsi corti; entrambi i regimi condividono però la reward identica, quindi il contrasto primario resta internamente valido e l'avvertenza riguarda la sola prestazione *assoluta* sui percorsi hard. La generalizzazione, infine, è misurata su esattamente un trasferimento, e le affermazioni sono limitate a questa coppia di mappe. Va anche ricordato che la pipeline di valutazione stessa ha fallito la validità una volta e che il difetto di lunghezza dei percorsi ha ridefinito silenziosamente la distribuzione dei task per un'intera era di esperimenti (Sezione 3.3): in una piattaforma custom, gli effetti apparenti devono prima sopravvivere alla domanda “lo strumento sta misurando ciò che dichiara?”.

Limiti di scope. Il design fissa infine diverse dimensioni, e i risultati non vanno letti oltre di esse (Sezione 3.4). L'architettura degli *actor* è fissa, quindi l'asse GNN parla della sola stima del valore sotto CTDE; la cornice a mondo condiviso non è ablata, quindi il suo contributo causale è caratterizzato e non isolato; le osservazioni sono privilegiate e non percettive, quindi nulla segue per pipeline basate su camera o lidar; e l'algoritmo e la versione della piattaforma sono unici, quindi altri algoritmi possono interagire diversamente con l'ordinamento.

Capitolo 5

Possibili evoluzioni

Le direzioni che seguono sono ordinate per prossimità: prima quelle che consolidano l'evidenza già raccolta, poi quelle che rimuovono i limiti noti della piattaforma, infine quelle che estendono la domanda a un terreno nuovo. Le prime due categorie sono realizzabili sul codice esistente e su un budget di calcolo confrontabile con quello di questa tesi, la terza no.

5.1 Consolidare l'evidenza

Replicazione dei seed. È l'estensione più diretta e la più importante. Il design è stato tagliato da tre seed appaiati per cella a uno per ragioni di calcolo (Sezione 3.4), e questa riduzione è la fonte principale di cautela in tutta la tesi. Rieseguire la matrice 2×2 a $n=3$ trasformerebbe i casi di studio appaiati in stime di distribuzione e metterebbe alla prova direttamente l'entità dell'interazione architettura $\times$ regime, che è oggi il risultato più forte e al tempo stesso il meno replicato. Il costo è noto e lineare: otto run da tre milioni di passi in aggiunta alle quattro esistenti.

Spiegare l'erosione. La degradazione entro la run controllata per livello (Tabella 4.2) è presente in tutte le celle e dimezzata sotto il critic relazionale, e la tesi ne identifica due cause candidate senza poterle separare. Due ablazioni mirate lo farebbero: congelare una classe di agenti a metà addestramento isolerebbe la co-adattazione tra classi, e spostare l'ancora dell'annealing di entropia isolerebbe lo schedule di esplorazione. Entrambe sono modifiche di poche righe sulla piattaforma esistente e girano al budget diagnostico del protocollo di gate.

Selezione del checkpoint. Poiché i numeri finali sottostimano i picchi di metà addestramento in ogni cella (Sezione 4.9), un'analisi che valuti il *miglior* checkpoint anziché l'ultimo direbbe se l'ordinamento dei task cambi anche il punto in cui la competenza

culmina, e non solo quello in cui atterra. I checkpoint intermedi sono già su disco: è un'estensione della sola pipeline di valutazione.

5.2 Rimuovere i limiti della piattaforma

Generazione dei percorsi pedonali. Con più della metà dei percorsi pedonali sotto target su Town03 (Sezione 4.7), un planner consapevole della fattibilità — esplorazione più profonda delle ramificazioni, target adattivi per regione di spawn, rinuncia esplicita quando la topologia locale non sostiene la distanza richiesta — è la correzione d'ambiente a maggior leva: renderebbe interpretabili i tassi di successo medium e hard che questa tesi è costretta a leggere solo entro livello, oggi vincolati da un soffitto comune a tutte le celle.

Co-design di reward e curriculum. Il tuning della reward guidato da gate è girato per lo più su configurazioni bloccate su easy (Sezione 4.10), quindi lo shaping del trunk può essere implicitamente sbilanciato verso i percorsi corti. Ricalibrare i termini chiave sul mix completo quantificherebbe quanto dell'effetto di regime sia mediato dalla calibrazione della reward, e metterebbe alla prova la spiegazione avanzata per il fallimento di H1.

5.3 Estendere la domanda

Estensioni architetturali sul critic. L'infrastruttura espone già encoder basati su attenzione (GAT) e la normalizzazione del valore PopArt dietro flag di configurazione (Sezione 2.7). Vista la forza dell'interazione osservata con l'encoder del critic, queste non sono aggiunte esotiche ma le celle successive naturali della stessa matrice: se sostituire un MLP con un message passing a media sposta il *luogo* dell'effetto di regime, la domanda immediatamente successiva è se un'aggregazione pesata da attenzione lo sposti ancora.

Curricula adattivi. Il gate di competenza di questa tesi è un sequenziatore fisso a due soglie. Curricula che adattano le quote di livello in continuo — per esempio campionando in proporzione al progresso di apprendimento misurato per livello — metterebbero alla prova se l'effetto di selezione dell'equilibrio sopravviva a un ordinamento a grana molto più fine, o se dipenda proprio dalla discontinuità degli sbocchi.

Scalare la cornice. La copertura parallela dei task è stata fissata a 3+3 agenti. Scalare il mondo condiviso verso decine di agenti — dove la struttura relazionale del critic GNN dovrebbe contare di più — trasforma la cornice di coesistenza stessa in una variabile sperimentale, e sposta il lavoro dalla caratterizzazione di un effetto alla sua legge di scala. È l'unica direzione che richiede un'infrastruttura di calcolo sostanzialmente diversa da quella usata qui (Capitolo D).

Capitolo 6

Conclusioni

Questa tesi ha chiesto se ordinare i task di addestramento dal facile al difficile produca un comportamento di guida multi-agente misurabilmente diverso rispetto al presentare tutte le difficoltà insieme, a parità di budget, in un ambiente CARLA a mondo condiviso addestrato con MAPPO. La risposta è sì — ma non lungo l’asse su cui i curricula vengono di solito proposti.

L’ordinamento non ha accelerato l’apprendimento. Tutte e quattro le celle della campagna hanno raggiunto le stesse soglie iniziali di competenza agli stessi conteggi di passi, con uno scarto sotto l’8% (Sezione 4.2), e questo pur avendole superate su mix di difficoltà completamente diversi. La spiegazione più plausibile è che il reward shaping denso di questa piattaforma fornisca già segnale di apprendimento anche sui task difficili, rendendo superfluo l’avvio graduale: una condizione di scope su H1, non una confutazione del curriculum learning in generale.

L’ordinamento ha selezionato ciò che la policy è diventata. Sotto il critic MLP il curriculum ha prodotto un guidatore cauto e incline allo stallo e il batch uno veloce e incline alle collisioni; sul criterio di successo rigoroso lo scambio si è risolto a favore del curriculum di +18.5 pp in valutazione, coerentemente in tutti e quattro gli scenari (Sezione 4.3). L’ordinamento dei task agisce cioè da *selettore di equilibri* sul trade-off velocità-sicurezza, più che da acceleratore.

L’effetto è condizionato dalla stima del valore. Sotto un critic GNN l’effetto di regime in-domain è svanito (−0.1 pp) mentre l’architettura ha recuperato la cella batch e rimodellato la cella curriculum: una forte interazione architettura×regime (Sezione 4.6). Il regime di addestramento non è quindi una leva indipendente dal resto dello stack, e riportarne l’effetto senza dichiarare l’architettura del critic è riportarne solo metà.

Il beneficio portabile è la generalizzazione. L'unica componente del vantaggio del curriculum replicata in entrambe le architetture è il margine su una città mai vista in addestramento (+19.0 e +10.0 pp su Town05), ottenuta contro l'intuizione copertura-implica-robustezza che motivava H2 (Sezione 4.5). È il risultato che questa tesi difende con più forza, perché è l'unico osservato due volte in modo indipendente.

Specificità di classe e limiti della piattaforma. I pedoni sono risultati in larga parte insensibili al regime, vincolati dalla fattibilità dei percorsi più che dalla qualità della policy (Sezione 4.7); e ogni cella ha mostrato erosione tardiva entro la run a livello di task fissato, indipendente dal regime (Sezione 4.4). Le scelte di regime calibrate sulla classe forte non vanno assunte trasferibili alla debole.

Oltre ai risultati, la tesi contribuisce l'apparato che li ha resi misurabili: un framework di confronto a parità di budget con configurazioni appaiate per seed e byte-identiche; un protocollo di sviluppo guidato da gate con un registro esplicito di modifiche promosse, rigettate e consapevolmente mantenute; un resoconto documentato di come i difetti di validità dell'ambiente possano mascherarsi da effetti di policy, con le loro firme di rilevamento; e un metro di varianza da repliche a seed identico contro cui ogni affermazione viene letta. In un contesto in cui un singolo bug del simulatore ha spostato la metrica principale di cinquanta punti percentuali senza che nulla cambiasse nella policy, questa disciplina di misura — e non un singolo numero — è ciò che rende il confronto significativo.

Resta il limite che la tesi dichiara apertamente e che il Capitolo 5 mette in cima all'elenco: con una run per cella, ogni contrasto è un caso di studio appaiato letto contro una banda di rumore, non la stima di una distribuzione. La replicazione sui seed della matrice 2×2 è il passo che trasformerebbe le conclusioni qui riportate da direzioni ben corroborate in effetti quantificati.

Appendice A

Osservazioni e reward per componente

Le due tabelle che seguono danno il dettaglio per componente degli spazi di osservazione (Sezione 2.3) e della funzione di reward (Sezione 2.4), la cui struttura e il cui razionale sono descritti nel Capitolo 2. Tutti i valori sono verificati dal codice del trunk di campagna.

Tabella A.1: Layout delle osservazioni. Le barre indicano costanti di normalizzazione; le feature dei vicini sono nel sistema di riferimento dell'ego. TTC = time-to-collision.

Dim.	Gruppo	Contenuto
<i>Veicolo (47D)</i>		
0–12	Ego e percorso	velocità (/30), accelerazione (/10), modulo (/120 km/h), heading; distanza (/50 m) e bearing al waypoint successivo; offset laterale in corsia; progresso continuo
13–23	Semaforo, vicini	flag e stato del semaforo; 3 veicoli più prossimi entro 50 m (offset long. e lat. /50, velocità relativa /30)
24–33	Anteprima e geometria	sterzo precedente; waypoint +1/+3/+5; errore di heading; angolo curva imminente; errore laterale con segno
34–43	Pedoni e hazard	2 pedoni più prossimi, stesse 3 feature; rischio TTC e occupazione del corridoio, vs. veicoli e vs. pedoni
44–46	Progresso/tempo	passi senza progresso (/300); flag anti-loop; tempo rimanente
<i>Pedone (26D)</i>		
0–11	Ego e waypoint	posizione (x, y /500, z /50); velocità (/5); vettore frontale; distanza (/100 m) e bearing al waypoint; flag marciapiede
12–17	Veicoli vicini	2 più prossimi entro 50 m: stesse 3 feature
18–25	Percorso e hazard	completamento; waypoint +1/ +3 (/100); errore di heading; rischio TTC e occupazione vs. veicoli

Tabella A.2: Componenti della reward. Le righe veicolo “gated” sono sospese durante l’attesa a un semaforo rosso/giallo; le righe marcate [†] richiedono inoltre *safe_to_push* (*hazard* < 0.85) e allineamento al percorso > 0.25.

Componente	Trigger	Valore
<i>Veicolo</i>		
Waypoint raggiunto / saltato	per waypoint avanzato / saltato	+100 / -10
Progresso denso	variazione della distanza dal waypoint	+4.0 per metro guadagnato
Collisione	primo contatto (terminale)	-500
Fuori corsia / eccesso di velocità	> 2 m dal centro corsia / $v > 50$ km/h	-0.5 per metro / -0.10 per km/h
Inattività (gated)	velocità < 2.5 km/h	-0.15
Bonus di partenza (gated [†])	acceleratore da fermo	$(0.20 + 0.30 u) \cdot \text{thr} \cdot \text{align}$, freno simmetrico; $u = \min(\text{no-progress}/200, 1)$
Shaping velocità minima (gated [†])	velocità sotto / sopra 8 km/h	$-0.04(8-v) \cdot \text{align}$ / $+0.15 \cdot \text{align}$
Rampa di non-progresso (gated)	> 100 passi senza waypoint	-0.004 per passo, tetto -1.0
Sterzo fluido / a strattoni	$ \Delta \text{steer} < 0.1$ a > 5 km/h / > 0.5	+0.1 / -0.3
Anti-loop	rilevatore di loop attivo	-1.0
<i>Pedone</i>		
Waypoint raggiunto / saltato	per waypoint avanzato / saltato	+50 / -10
Progresso denso	variazione della distanza dal waypoint	+2.0 per metro guadagnato
Collisione	primo contatto (terminale)	-50
Marciapiede / carreggiata	per passo su marciapiede / corsia	+0.2 / -0.3
Passo di camminata	velocità $\in [1.2, 2.6]$ m/s	+0.3
Inattività / corsa	velocità < 0.15 m/s / > 3.0 m/s	-0.15 / -0.7 per m/s oltre m/s
Anti-loop	rilevatore di loop attivo	-1.0

Appendice B

Registro condensato degli esperimenti

La Tabella B.1 elenca i candidati valutati durante la fase di sviluppo guidata da gate (Sezione 3.2) con il verdetto e l'esito di sintesi. Le run A/B sono da 3×10^5 passi, seed 999, bloccate su easy salvo diversa indicazione; i delta sono rispetto alla baseline appaiata della loro era e *non* sono confrontabili tra versioni dell'ambiente (Sezione 3.3). Il registro completo, con meccanismi e identificatori di run per candidato, è mantenuto nel repository.

Tabella B.1: Registro condensato dei candidati.

Candidato	Tipo	Verdetto	Sintesi
Correzione lunghezza percorsi	bug fix	adottato	$\approx +50$ pp SR (cambio di distribuzione)
Correzione seed percorsi	bug fix	adottato	ripristina l'appaiamento A/B
Osservabilità 47D	osservazione	adottato	baseline sana, var. spiegata 0.983
Blocco di reward shaping anti-stallo	reward	promosso	nucleo della Sezione 2.4
Rimozione guardia di progresso	reward	promosso	SR $+4.7$ pp, $s+t -3.5$ pp
Tolleranza hazard $0.75 \rightarrow 0.85$	reward	promosso	5/5: SR $+2.3$ pp, $s+t -3.0$ pp
Tetto attraversamenti $8 \rightarrow 3$	percorsi	promosso	SR $+9.2$ pp, coll. -2.3 pp, off. -2.2 pp
Schedule di entropia a frazione	ottimizzatore	promosso	meccanismo stabile, nessuna instabilità
Riparazione value loss	ottimizzatore	mantenuto (gate fallito)	var. spiegata $0 \rightarrow 0.87$; collisione $+3.3$ pp
Sconto $0.99 \rightarrow 0.997$	ottimizzatore	mantenuto (falsificato)	timeout $\rightarrow$ collisione $\approx 1:1$
Penalità di collisione $\times 10$	reward	mantenuto (falsificato)	collisione piatta: limite di percezione, non di peso
Terminazione precoce da stuck	dinamica env	rigettato	SR -2.9 pp, $s+t +7.1$ pp
Retuning banda di passo pedoni	reward	rigettato	overshoot peggiore; declino in Q4
<code>route_short</code> come successo	misura	revertito	violava il criterio di successo

Appendice C

Configurazione e iperparametri

La Tabella C.1 riporta la configurazione completa delle quattro run di campagna. Tutti i valori sono identici tra le celle a meno dei due flag sperimentali (`mode` e `use_gnn`), proprietà verificata con un diff diretto dei `run_config.json` scritti al lancio, che restano il riferimento autoritativo per ogni singola run. Le famiglie di livelli per densità di traffico e miste sono definite in configurazione ma inutilizzate in questa tesi (Sezione 3.4).

Tabella C.1: Configurazione delle run di campagna.

Gruppo	Parametro	Valore
<i>Ottimizzazione (PPO/MAPPO)</i>		
	learning rate	5×10^{-4}
	γ	0.997
	GAE λ	0.95
	clip PPO ε	0.2
	penalità KL	attiva; target 0.02, coefficiente iniziale 0.3
	gradient clipping	0.5
	vf_clip_param	10^6 (clamp non vincolante)
	vf_loss_coeff	0.05
	coefficiente di entropia	schedule a frazione del budget: 0.03 a 0.0, 0.005 a 0.83
<i>Rollout e batching</i>		
	frammento di rollout	200 passi
	batch di addestramento	8.000 passi
	minibatch SGD	256
	epoche SGD per batch	15
	budget totale	3×10^6 passi d'ambiente
	frequenza di checkpoint	ogni 10^5 passi
<i>Modello</i>		
	actor (entrambe le classi)	MLP, 2 strati nascosti da 256
	critic MLP	$225 \rightarrow 256 \rightarrow 256 \rightarrow 1$
	critic GNN	embedding di nodo 64, 2 layer di message passing, aggregazione a media, ELU disabilitati
	PopArt, attenzione	
<i>Curriculum</i>		
	finestra di competenza	50 episodi (deve essere piena)
	metrica di sblocco	minimo dell'SR a finestra sulle due policy
	soglia medium / hard	0.70 / 0.60
	quota minima di budget	easy ≥ 0.20 prima di medium; medium ≥ 0.28 prima di hard
	cap di pressione	medium al 30% del budget, hard al 70%
	pesi di campionamento	1.00/1.17/1.17 ($\rightarrow$ 0.30/0.35/0.35)
	vincoli di budget	easy ≤ 0.30 , medium ≤ 0.35 , hard ≥ 0.35
	probation	2 blocchi dopo lo sblocco (1 dopo un cap); peso hard 0.85
<i>Batch</i>		
	campionamento	mescolamento stratificato senza reinserimento, finestra 3
<i>Livelli (difficoltà = lunghezza percorso)</i>		
	easy / medium / hard	Town03, 30 m / 60 m / 100 m
	test (solo valutazione)	Town05, 80 m
	traffico NPC	15 veicoli, 30 pedoni in ogni livello

Appendice D

Riproducibilità

Stack software. CARLA 0.9.16 (server e API Python); Python 3.11.9; PyTorch 2.7 (CUDA 12.6); Ray/RLlib 2.10.0. Addestramento e simulatore girano sulla stessa macchina.

Hardware. Tutte le run sono state eseguite su una singola macchina di classe laptop: Intel Core i7-10870H (8 core / 16 thread), 16 GB di RAM, NVIDIA GeForce RTX 3080 Laptop GPU (8 GB), Windows 11. L’inviluppo di risorse è parte dei vincoli di design dello studio: motiva il budget diagnostico da 3×10^5 passi del protocollo di gate (Sezione 3.2) e la riduzione della campagna a un singolo seed per cella (Sezione 3.4).

Versione del codice e dati grezzi. Il trunk di campagna è il commit 7defb03; i commit successivi fino alla stesura di questa tesi toccano solo documentazione e tooling di visualizzazione. Ogni directory di run conserva il proprio `run_config.json`, i checkpoint e `episodes.jsonl` — i record grezzi a livello di agente da cui ogni numero di questa tesi è ricalcolato. Le quattro run di campagna sono 20260622_171626 (MLP-curriculum), 20260623_171855 (MLP-batch), 20260630_181143 (GNN-curriculum) e 20260714_155209 (GNN-batch).

Comandi. Addestramento (uno per cella; le quattro celle variano solo `-mode` e `-use-gnn`):

```
python -m carla_core.training.train_carla_mappo -mode curriculum
        -difficulty path -timesteps 3000000 -seed 999 [-use-gnn]
```

L’addestramento scrive un `final_eval_job.json` nella directory della run; la valutazione finale a 400 episodi si lancia con:

```
python -m carla_core.training.evaluate_carla_mappo
        -job <run_dir>/final_eval_job.json
```

Seed. Campagna: un unico seed di esperimento (999), appaiato tra le quattro celle; i seed dei percorsi per agente ne derivano deterministicamente (Sezione 2.2). Si noti che il seeding *non* rende identiche le run CARLA (Sezione 4.10): riproducibilità qui significa riprodurre la *distribuzione* degli esiti, e ogni aggregato riportato a partire dai log archiviati.

Bibliografia

- [1] Richard S. Sutton e Andrew G. Barto. *Reinforcement Learning: An Introduction*. 2^a ed. Cambridge, MA: MIT Press, 2018.
- [2] John Schulman et al. *Proximal Policy Optimization Algorithms*. 2017. arXiv: 1707.06347.
- [3] John Schulman et al. «High-Dimensional Continuous Control Using Generalized Advantage Estimation». In: *International Conference on Learning Representations (ICLR)*. arXiv:1506.02438. 2016.
- [4] Ryan Lowe et al. «Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments». In: *Advances in Neural Information Processing Systems 30 (NIPS)*. 2017.
- [5] Chao Yu et al. «The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games». In: *Advances in Neural Information Processing Systems 35 (NeurIPS), Datasets and Benchmarks Track*. 2022.
- [6] Jeffrey L. Elman. «Learning and Development in Neural Networks: The Importance of Starting Small». In: *Cognition* 48.1 (1993), pp. 71–99.
- [7] Yoshua Bengio et al. «Curriculum Learning». In: *Proceedings of the 26th International Conference on Machine Learning (ICML)*. 2009, pp. 41–48.
- [8] Sanmit Narvekar et al. «Curriculum Learning for Reinforcement Learning Domains: A Framework and Survey». In: *Journal of Machine Learning Research* 21.181 (2020), pp. 1–50.
- [9] Robert M. French. «Catastrophic Forgetting in Connectionist Networks». In: *Trends in Cognitive Sciences* 3.4 (1999), pp. 128–135.
- [10] Alexey Dosovitskiy et al. «CARLA: An Open Urban Driving Simulator». In: *Proceedings of the 1st Annual Conference on Robot Learning (CoRL)*. Vol. 78. Proceedings of Machine Learning Research. 2017, pp. 1–16.
- [11] CARLA Team. *CARLA Simulator Documentation*. URL: <https://carla.readthedocs.io> (visitato il giorno 14/07/2026).

- [12] William L. Hamilton, Zhitao Ying e Jure Leskovec. «Inductive Representation Learning on Large Graphs». In: *Advances in Neural Information Processing Systems 30 (NIPS)*. 2017, pp. 1024–1034.